

1. Цель работы

Разработка и исследование рекуррентной нейронной сети на основе LSTM для задачи анализа тональности текстов (сентимент-анализа) на датасете IMDB Reviews, содержащем 50 000 отзывов на фильмы с бинарной классификацией (положительный/отрицательный).

2. Теоретическая часть

2.1 Рекуррентные нейронные сети (RNN)

В отличие от сетей прямого распространения, обрабатывающих каждый вход независимо, RNN обладают внутренней памятью. На каждом временном такте рекуррентный нейрон получает текущий элемент последовательности и предыдущее скрытое состояние, аккумулирующее информацию о предыстории.

2.2 Проблема классических RNN

Классические RNN страдают от проблемы затухающих (vanishing) и взрывающихся (exploding) градиентов, что делает невозможным обучение долгосрочным зависимостям.

2.3 Архитектура LSTM (Long Short-Term Memory)

LSTM решает проблему долгосрочных зависимостей путем введения ячейки памяти, состояние которой контролируется тремя вентилями:

Вентиль	Формула	Назначение
---------	---------	------------

Forget gate (забывания)	$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$	Определяет, какую информацию удалить из памяти
-------------------------	--	--

Input gate (входа)	$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$	Определяет, какую новую информацию сохранить
--------------------	--	--

Output gate (выхода)	$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$	Определяет, что передать на выход
----------------------	--	-----------------------------------

Обновление состояния ячейки:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$h_t = o_t \odot \tanh(C_t)$$

где σ — сигмоида, $\odot$ — поэлементное умножение.

2.4 Архитектура GRU (Gated Recurrent Unit)

GRU — упрощенная версия LSTM с 2 вентилями (сброса и обновления), требующая меньше вычислительных ресурсов при сопоставимом качестве.

3. Практическая реализация

3.1 Инструментарий

Компонент Спецификация

Язык программирования Python 3.11

Библиотека ML PyTorch (без Keras/FastAI)

GPU NVIDIA GeForce RTX 4070 (12.9 GB VRAM)

CUDA Поддерживается

3.2 Подготовка данных (п. 1 ТЗ)

Пункт ТЗ Выполнено

1.1 Загрузка 50000 отзывов из CSV

1.2 Словарь на 20000 частотных слов + токены <PAD> и <UNK>

1.3 Преобразование отзывов в индексы

1.4 Padding до длин 128, 256, 512 токенов

1.5 DataLoader с batch_size=64, разделение 80/20

Статистика датасета:

Обучающая выборка: 40 000 отзывов

Тестовая выборка: 10 000 отзывов

Средняя длина отзыва: 227.2 токенов

Максимальная длина: 2450 токенов




Рисунок 1 – Распределение длин отзывов в обучающей выборке

3.3 Архитектура модели (п. 2 ТЗ)

class LSTMClassifier(nn.Module):

```
def __init__(self, vocab_size=20000, embedding_dim=128,
              hidden_dim=128, num_layers=2, dropout=0.5):
    self.embedding = nn.Embedding(20000, 128, padding_idx=0)
    self.lstm = nn.LSTM(128, 128, 2, batch_first=True,
                        bidirectional=True, dropout=0.5)
    self.dropout = nn.Dropout(0.5)
    self.fc = nn.Linear(256, 1) # 256 = 128*2 (bidirectional)
    self.sigmoid = nn.Sigmoid()
```

Параметры модели:

Слой эмбедингов: 20000×128

LSTM слой: 2 слоя, размер скрытого состояния 128, двунаправленный

Dropout: 0.5

Классификатор: $\text{Linear}(256 \rightarrow 1) + \text{Sigmoid}$

3.4 Параметры обучения (п. 3 ТЗ)

Параметр	Значение
Функция потерь	BCELoss (бинарная перекрестная энтропия)
Оптимизатор	Adam
Learning rate	0.001
Batch size	64
Эпохи	5 (в диапазоне 5-10 по ТЗ)
Регуляризация	Dropout (0.5), обрезка градиентов

4. Результаты экспериментов

4.1 Эксперимент 1: Влияние длины последовательности (п. 5 ТЗ)




Рисунок 2 – Влияние длины последовательности на качество классификации

Вывод: Оптимальная длина последовательности — 256 токенов (88.02%). Дальнейшее увеличение до 512 токенов не повышает точность, но увеличивает время обучения в 1.8 раза.

4.2 Эксперимент 2: Сравнение LSTM и GRU (п. 6 ТЗ)

Параметр	LSTM	GRU
Количество параметров	3,219,713	3,054,849
Точность на тесте	87.35%	88.84%
Время эпохи	7.7 с	5.2 с

Финальные потери 0.3700 0.3291

Рисунок 3 – Сравнение LSTM и GRU (потери и точность)




Рисунок 4 – Сравнительная таблица LSTM и GRU

Сравнение архитектур LSTM и GRU (5 эпох)

Параметр	LSTM	GRU
Количество параметров	3,219,713	3,054,849
Точность на тесте (%)	87.35	88.84
Финальные потери	0.3700	0.3291
Время обучения (5 эпох, сек)	1.9	1.4

Вывод: GRU показал лучший результат (88.84% против 87.35%), обучается быстрее (5.2 с против 7.7 с за эпоху) и имеет меньше параметров. Это объясняется тем, что для задачи сентимент-анализа достаточно упрощенной архитектуры GRU.

4.3 Эксперимент 3: Анализ ошибок (п. 7 ТЗ, Вариант Б)

Группа длины Количество примеров Точность

Короткие (0-100) 1 298 89.75%

Средние (100-300) 6 600 88.29%

Длинные (300-600) 1 659 84.45%

Очень длинные (600+) 443 77.20%




Рисунок 5 – Зависимость точности от длины отзыва

Анализ:

Наилучшая точность (89.75%) — короткие отзывы (менее 100 токенов). В таких отзывах мнение выражено лаконично и однозначно.

Наихудшая точность (77.20%) — очень длинные отзывы (более 600 токенов). Длинные отзывы часто содержат противоречивую информацию (сначала хвалят, потом ругают), что затрудняет классификацию.

5. Сравнение с базовым уровнем

Модель	Точность	Превышение над случайным
--------	----------	--------------------------

Случайное угадывание	50.00%	—
----------------------	--------	---

GRU (данная работа)	88.84%	+38.84%
---------------------	--------	---------

LSTM (данная работа)	87.35%	+37.35%
----------------------	--------	---------

Лучшие LSTM модели (известные)	85-90%	—
--------------------------------	--------	---

Результаты (88.84%) находятся в верхней границе известных результатов для LSTM на IMDB (85-90%).

6. Выводы

Разработана рекуррентная нейронная сеть на основе LSTM для бинарной классификации отзывов IMDB.

Исследовано влияние длины последовательности: оптимальная длина — 256 токенов (точность 88.02%). Дальнейшее увеличение не улучшает качество, но растет время обучения.

Проведено сравнение LSTM и GRU: GRU показал лучший результат (88.84% против 87.35%), обучается быстрее и имеет меньше параметров.

Выполнен анализ ошибок по длине отзывов:

Короткие отзывы (0-100 токенов) — лучшая точность (89.75%)

Очень длинные отзывы (600+) — худшая точность (77.20%) из-за противоречивой информации

Достигнутая точность (88.84%) соответствует лучшим известным результатам для LSTM/GRU на датасете IMDB.

Используемое устройство: cuda
GPU: NVIDIA GeForce RTX 4070
Видеопамять: 12.9 GB

=====

===

=====

===

1. ЗАГРУЗКА И ПОДГОТОВКА ДАННЫХ (ПО ТЗ 1.1-1.5)

=====

===

Загрузка IMDB Dataset.csv...

Загружено 50000 строк (всего 50000 отзывов)

Обучающая выборка: 40000 примеров

Тестовая выборка: 10000 примеров

2. ТОКЕНИЗАЦИЯ И ПОСТРОЕНИЕ СЛОВАРЯ (ПО ТЗ 1.2-1.3)

Очистка текстов...

Построение словаря на 20000 наиболее частотных слов...

Реальный размер словаря: 20000

Примеры слов: ['<PAD>', '<UNK>', 'the', 'a', 'and', 'of', 'to', 'is', 'in', 'it']

Преобразование текстов в индексы...

Средняя длина отзыва: 227.2 токенов

Максимальная длина: 2450

3. PADDING ПОСЛЕДОВАТЕЛЬНОСТЕЙ (ПО ТЗ 1.4)

max_len=128: train батчей=625, test батчей=157

max_len=256: train батчей=625, test батчей=157

max_len=512: train батчей=625, test батчей=157

Сохранен график: 1_length_distribution.png

4. РЕАЛИЗАЦИЯ МОДЕЛЕЙ (ПО ТЗ РАЗДЕЛ 2)

ЭКСПЕРИМЕНТ 1: ВЛИЯНИЕ ДЛИНЫ ПОСЛЕДОВАТЕЛЬНОСТИ (ПО ТЗ РАЗДЕЛ 5)

--- Обучение с max_len=128 (5 эпох) ---

Параметров модели: 3,219,713

Обучение LSTM_len128 на cuda...

Эпоха 1/5 (5.4с)

Train Loss: 0.6193, Train Acc: 65.77%

Test Loss: 0.6155, Test Acc: 63.57%

Эпоха 2/5 (4.8с)

Train Loss: 0.4926, Train Acc: 76.99%

Test Loss: 0.4404, Test Acc: 80.02%

Эпоха 3/5 (4.8с)

Train Loss: 0.3773, Train Acc: 83.61%

Test Loss: 0.3739, Test Acc: 83.71%

Эпоха 4/5 (4.8с)

Train Loss: 0.2994, Train Acc: 87.96%

Test Loss: 0.3842, Test Acc: 84.37%

Эпоха 5/5 (4.5с)

Train Loss: 0.2489, Train Acc: 90.20%

Test Loss: 0.3922, Test Acc: 84.61%

--- Обучение с max_len=256 (5 эпох) ---

Параметров модели: 3,219,713

Обучение LSTM_len256 на cuda...

Эпоха 1/5 (8.0с)

Train Loss: 0.6218, Train Acc: 65.58%

Test Loss: 0.5180, Test Acc: 75.82%

Эпоха 2/5 (8.2с)

Train Loss: 0.4360, Train Acc: 81.88%

Test Loss: 0.3941, Test Acc: 84.03%

Эпоха 3/5 (8.1с)

Train Loss: 0.3375, Train Acc: 86.60%

Test Loss: 0.3766, Test Acc: 84.11%

Эпоха 4/5 (8.2с)

Train Loss: 0.2692, Train Acc: 89.51%

Test Loss: 0.3508, Test Acc: 86.14%

Эпоха 5/5 (8.1с)

Train Loss: 0.2196, Train Acc: 91.81%

Test Loss: 0.3230, Test Acc: 88.02%

--- Обучение с max_len=512 (5 эпох) ---

Параметров модели: 3,219,713

Обучение LSTM_len512 на cuda...

Эпоха 1/5 (14.2с)

Train Loss: 0.6185, Train Acc: 65.69%

Test Loss: 0.5109, Test Acc: 76.20%

Эпоха 2/5 (14.3с)

Train Loss: 0.4729, Train Acc: 79.08%

Test Loss: 0.4838, Test Acc: 78.57%

Эпоха 3/5 (14.7с)

Train Loss: 0.3887, Train Acc: 84.14%

Test Loss: 0.3734, Test Acc: 84.46%

Эпоха 4/5 (15.6с)

Train Loss: 0.3026, Train Acc: 88.33%

Test Loss: 0.3286, Test Acc: 86.92%

Эпоха 5/5 (14.4с)

Train Loss: 0.2489, Train Acc: 90.62%

Test Loss: 0.3202, Test Acc: 87.54%

Сохранен график: 2_length_analysis.png

ЭКСПЕРИМЕНТ 2: СРАВНЕНИЕ LSTM и GRU (ПО ТЗ РАЗДЕЛ 6)

LSTM параметров: 3,219,713

Обучение LSTM на cuda...

Эпоха 1/5 (7.8с)

Train Loss: 0.6667, Train Acc: 58.48%

Test Loss: 0.6584, Test Acc: 62.67%

Эпоха 2/5 (7.8с)

Train Loss: 0.4905, Train Acc: 76.81%

Test Loss: 0.3805, Test Acc: 83.57%

Эпоха 3/5 (7.8с)

Train Loss: 0.3192, Train Acc: 87.10%

Test Loss: 0.3327, Test Acc: 86.50%

Эпоха 4/5 (7.6с)

Train Loss: 0.2417, Train Acc: 90.88%

Test Loss: 0.3215, Test Acc: 87.53%

Эпоха 5/5 (7.6с)

Train Loss: 0.1895, Train Acc: 93.39%

Test Loss: 0.3700, Test Acc: 87.35%

GRU параметров: 3,054,849

Обучение GRU на cuda...

Эпоха 1/5 (5.2с)

Train Loss: 0.5849, Train Acc: 67.32%

Test Loss: 0.4135, Test Acc: 81.65%

Эпоха 2/5 (5.2с)

Train Loss: 0.3229, Train Acc: 86.36%

Test Loss: 0.2947, Test Acc: 87.79%

Эпоха 3/5 (5.2с)

Train Loss: 0.2236, Train Acc: 91.28%

Test Loss: 0.2880, Test Acc: 88.96%

Эпоха 4/5 (5.2с)

Train Loss: 0.1543, Train Acc: 94.11%

Test Loss: 0.2928, Test Acc: 88.92%

Эпоха 5/5 (5.2с)

Train Loss: 0.0964, Train Acc: 96.72%

Test Loss: 0.3291, Test Acc: 88.84%

Сохранен график: 3_lstm_gru_comparison.png

Сохранен график: 4_comparison_table.png

ЭКСПЕРИМЕНТ 3: АНАЛИЗ ОШИБОК (ВАРИАНТ Б - ПО ДЛИНЕ, ПО ТЗ РАЗДЕЛ 7)

Короткие (0-100): 1298 примеров, точность=89.75%
Средние (100-300): 6600 примеров, точность=88.29%
Длинные (300-600): 1659 примеров, точность=84.45%
Очень длинные (600+): 443 примеров, точность=77.20%
Сохранен график: 5_error_analysis.png

ИТОГОВЫЕ РЕЗУЛЬТАТЫ И ВЫВОДЫ



РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ:

1. Влияние длины последовательности (раздел 5 ТЗ, 5 эпох):

max_len=128: точность=84.61%, время=25.2с

max_len=256: точность=88.02%, время=40.5с

max_len=512: точность=87.54%, время=73.2с

2. Сравнение LSTM и GRU (раздел 6 ТЗ, 5 эпох):

LSTM: точность=87.35%, параметров=3,219,713

GRU: точность=88.84%, параметров=3,054,849

3. Анализ ошибок по длине (раздел 7, вариант Б):

Короткие (0-100): 89.75%

Средние (100-300): 88.29%

Длинные (300-600): 84.45%

Очень длинные (600+): 77.20%



ВЫВОДЫ:

- ✓ Увеличение длины последовательности повышает точность классификации
- ✓ LSTM показывает лучшие результаты, чем GRU на данной задаче
- ✓ Короткие отзывы классифицируются хуже из-за недостатка контекста
- ✓ Слишком длинные отзывы могут содержать противоречивую информацию